


1. Dalam konteks bisnis pertanian dan kebijakan pangan, apakah memprediksi kandungan organik tanah merupakan hal yang mendesak? Jelaskan urgensinya dari perspektif efisiensi biaya operasional dan manajemen lahan berkelanjutan!

Uji lab bahan organik tanah mahal, dan lambat dengan turnaround bisa berminggu-minggu [1]. Model spektral memangkas biaya operasional untuk pemetaan lahan skala besar, di mana satu scan spektral menggantikan puluhan sampel lab [2], [3]. Dari sisi manajemen lahan berkelanjutan, prediksi cepat memungkinkan keputusan real-time seperti rotasi tanam atau dosis pemupukan tanpa menunggu hasil lab, penting untuk kebijakan pangan yang butuh pemetaan kesuburan tanah nasional secara berkala, bukan sesekali [1], [4].

2. Apakah model prediksi kandungan organik tanah Anda mengalami *overfit* atau *underfit*? Tunjukkan buktinya secara empiris melalui metrik evaluasi atau melalui visualisasi yang relevan, serta jelaskan langkah mitigasi yang Anda lakukan! Jika tidak mengalami keduanya, jelaskan alasannya!



XGBoost: final train RMSE=4.0294, valid RMSE=11.3839, gap=7.3545
LightGBM: final train RMSE=6.2354, valid RMSE=11.4494, gap=5.2140
CatBoost: final train RMSE=10.3224, valid RMSE=12.1228, gap=1.8004

Dari learning curve di atas, XGBoost menunjukkan gap train-valid RMSE paling lebar, LightGBM sedang, dan CatBoost paling terkontrol. Artinya, XGBoost paling rentan overfit sementara CatBoost paling seimbang. Mitigasi yang diterapkan di pipeline meliputi early

stopping, regularisasi struktural, subsample dan colsample di bawah 1, serta Huber loss pada LightGBM dan CatBoost yang lebih robust terhadap outlier target yang skewed. Blending ketiga model lewat RidgeCV menghasilkan OOF RMSE yang lebih rendah dibanding model individu manapun, menandakan ensemble berhasil meredam overfitting masing-masing model.

3. Apakah ada pola distribusi kandungan organik tanah yang berbeda secara signifikan antar wilayah geografis? Berdasarkan pola tersebut, kira-kira kondisi ekosistem seperti apa yang paling dominan dalam dataset ini? Jelaskan reasoning Anda berdasarkan informasi ekologis dan tutupan lahan yang terlihat!

	count	mean	std	min	25%	50% \
biome						
Amazonia	1020.0	33.914792	19.880992	3.128191	21.034390	30.742570
Caatinga	100.0	44.898714	29.421622	11.682177	27.753260	37.271321
Cerrado	3760.0	34.133753	18.298047	3.595622	20.387178	29.286343
Mata Atlantica	4644.0	33.889063	26.137767	2.157373	17.151118	24.270450
Unknown	1686.0	34.359991	25.565953	2.479541	16.180300	25.939610

	75%	max
biome		
Amazonia	42.068780	148.427285
Caatinga	54.839082	195.231500
Cerrado	45.304840	181.219360
Mata Atlantica	41.421568	193.678191
Unknown	44.891919	177.061023

	count	mean	std	min	25%	50% \
geo_zone_macro						
MW	2930.0	34.500503	20.587121	5.393433	19.416360	29.124540
N	979.0	34.394741	19.625071	2.479541	22.652420	30.742570
NE	512.0	42.367177	31.220322	3.128191	19.254557	35.192152
S	1022.0	57.266801	36.452029	5.382646	25.672743	55.789674
SE	5767.0	29.089654	17.819009	2.157373	17.474724	24.270450

	75%	max
geo_zone_macro		
MW	46.922870	177.061023
N	42.068780	148.427285
NE	58.380140	195.231500
S	80.335189	191.186425
SE	35.758463	181.219360

land_cover_type		
Mixed Ombrophylous Forest		74.248605
Seasonal Deciduous Forest		69.180513
Steppe		45.098279
Open Ombrophylous Forest		42.139398
Dense Ombrophylous Forest		35.432299
Savannah		35.050507
Unknown		34.121648
Areas of Ecological Tension		33.187183
Seasonal Semideciduous Forest		27.667800
Areas of Pioneering Formation		22.857176
Amazon Rainforest		10.225556

Name: property_organic_content, dtype: float64

Ada beda signifikan antar wilayah geografis, tapi tidak terlalu terlihat antar biome. Pada level wilayah geografis makro, wilayah selatan jauh di atas wilayah tenggara. Pada level

biome, sebarannya relatif seragam kecuali satu biome dengan sampel kecil yang kurang reliable untuk ditarik kesimpulan. Yang paling jomplang justru pada tutupan lahan di area sampel, di mana hutan ombrofil campuran dan hutan deciduous musiman berada di ujung atas, sementara hutan hujan Amazon berada di ujung bawah. Secara ekologis, hutan hujan Amazon punya biomassa tinggi tapi dekomposisi cepat karena iklim tropis lembap, sehingga bahan organik tidak menumpuk di topsoil [5]. Sebaliknya, hutan ombrofil campuran atau deciduous yang dominan di wilayah selatan yang lebih subtropis-dingin punya dekomposisi lambat sehingga bahan organik terakumulasi. Kondisi ekosistem yang paling dominan di dataset ini adalah campuran savanna atau cerrado tropis dengan jumlah sampel besar dan kandungan organik menengah, dengan sebagian kecil hutan subtropis selatan yang tampil sebagai outlier tinggi.

4. Apakah ada korelasi kandungan organik tanah antar tingkat wilayah geografis? Berapa rasio perbandingan rata-rata kandungan organik antar wilayah tersebut, dan bagaimana ini memengaruhi pendekatan pemodelan Anda?

```
geo_zone_macro ratio max/min: 1.9686312481096366  
geo_zone_meso ratio max/min: 6.074489379783548  
geo_zone_micro ratio max/min: 11.979058837527516
```

Rasio antar level wilayah makin lebar seiring makin granularnya level geografis, dari makro ke meso ke mikro. Ini menunjukkan bahwa sebagian besar variasi kandungan organik tanah terjadi di level lokal atau mikro, bukan di level makro. Hal ini masuk akal karena kondisi tanah lebih dipengaruhi faktor lokal seperti drainase dan tutupan lahan spesifik dibanding zona geografis besar [6]. Implikasinya terhadap pemodelan adalah target encoding pada level meso atau mikro jauh lebih informatif dibanding hanya mengandalkan agregat level makro, sehingga pipeline melakukan target encoding di keempat level spasial sekaligus (macro, meso, mikro, dan biome).

5. Jawablah pertanyaan statistik berikut :

- a. Berapa rata-rata kandungan organik tanah dari tiap ekosistem ketika tingkat keasaman tanah berada di bawah persentil 25 dan kapasitas tukar kation berada di bawah rata-rata? Apa insight yang bisa didapat dari hal ini?

	mean	count
biome		
Amazonia	27.612371	197
Caatinga	19.982671	2
Cerrado	24.270450	2
Mata Atlantica	21.317980	186
Unknown	43.686810	1

Dari hasil di atas, hanya dua biome yang punya jumlah sampel cukup untuk ditarik kesimpulan, biome lainnya punya sampel terlalu sedikit sehingga tidak reliable. Pada kondisi tanah asam dan CEC rendah yang menandakan kesuburan kimiawi rendah, salah satu biome tetap menunjukkan kandungan organik yang lebih tinggi dibanding biome lain. Insight-nya adalah, pada biome tersebut, bahan organik lebih banyak berasal dari input biomassa organik seperti serasah hutan, bukan dari kompleks mineral-organik yang membutuhkan CEC tinggi untuk terbentuk.

- b. Apakah ada kombinasi jenis tutupan lahan dan wilayah geografis tertentu yang memiliki nilai kandungan organik yang dapat dianggap sebagai *outlier*? Jelaskan justifikasi Anda!

		mean	count
land_cover_type	geo_zone_macro		
Mixed Ombrophylous Forest	SE	84.946575	2
Open Ombrophylous Forest	NE	87.313522	7

Ada beberapa kombinasi tutupan lahan dan wilayah geografis yang nilainya berada jauh di luar rentang IQR keseluruhan dataset. Namun jumlah sampel pada kombinasi tersebut relatif kecil, sehingga statusnya sebagai outlier perlu dipertimbangkan dengan hati-hati, yang bisa jadi outlier valid akibat kombinasi kondisi hutan lembap dan tanah lokal spesifik, atau sekadar noise dari ukuran sampel kecil. Rekomendasinya adalah menjadikan kombinasi ini sebagai kandidat investigasi manual, bukan langsung di-drop dari training set.

6. Apakah ada pasangan variabel yang berkorelasi tinggi? Apakah ada efek multicollinearity yang perlu diatasi dalam modeling?

```
property_particle_coarse    property_particle_fine    -0.902199
property_particle_fine      property_particle_coarse    -0.902199
dtype: float64
```

```
property_particle_fine      1.585627
property_particle_coarse    1.545619
spectral_band_A_PC_13      1.508279
spectral_band_A_PC_8       1.443574
spectral_band_A_PC_12      1.407175
spectral_band_A_PC_11      1.399931
spectral_band_A_PC_6       1.396367
spectral_band_A_PC_4       1.390924
spectral_band_A_PC_7       1.382851
spectral_band_A_PC_10      1.366080
dtype: float64
```

Hanya ditemukan satu pasangan variabel yang berkorelasi tinggi, yaitu antara dua fraksi partikel tanah, di mana hal ini trivial secara konstruksi karena keduanya merupakan fraksi dari total yang sama sehingga otomatis berkorelasi negatif kuat. Nilai VIF tertinggi pun masih jauh di bawah threshold umum multicollinearity. Kesimpulannya, tidak ada masalah multicollinearity yang perlu diatasi dalam modeling, dan korelasi antar fraksi partikel bisa dibiarkan karena model tree-based yang digunakan (XGBoost, LightGBM, CatBoost) tidak sensitif terhadap multicollinearity seperti halnya model linear.

7. Fitur baru apa saja yang Anda buat melalui proses *feature engineering*? Jelaskan bagaimana fitur tersebut meningkatkan pemahaman model terhadap pola kandungan organik tanah!

Fitur baru yang dibuat terbagi menjadi tiga kelompok. Pertama, rasio kimiawi yang domain-informed seperti rasio kalsium-magnesium, rasio natrium terhadap kapasitas tukar kation, rasio base saturation, dan rasio partikel kasar-halus. Kedua, group-stats berupa mean dan standar deviasi dari indeks keasaman tanah dan kapasitas tukar kation, dikelompokkan per biome dan per zona geografis makro, di-fit hanya pada data train lalu diaplikasikan ke train dan test untuk mencegah leakage. Ketiga, target encoding spasial dengan smoothed mean encoding untuk keempat level geografis dan biome, menggunakan skema out-of-fold di dalam data train supaya tidak bocor. Fitur rasio base saturation dan fitur terkait CEC

berfungsi sebagai proxy kesuburan tanah yang berkorelasi langsung dengan kandungan organik, sehingga memberi model sinyal domain yang tidak eksplisit tersedia pada fitur mentah.

8. Jelaskan model yang Anda gunakan dalam memprediksi kandungan organik tanah! Mengapa Anda memilih model tersebut dibanding alternatif lain, khususnya dalam konteks data yang memiliki representasi spektral?

Model yang digunakan adalah ensemble dari XGBoost, LightGBM dengan Huber loss, dan CatBoost dengan Huber loss, yang kemudian digabung menggunakan RidgeCV dan optimasi SLSQP. Alasan pemilihan ketiganya, khususnya dalam konteks data dengan representasi spektral, adalah karena semuanya berbasis tree dan memiliki native null handling. Ini penting karena blok spektral band B (MIR, sangat sensitif terhadap bahan organik) memiliki missing value sebesar 85-89% akibat perbedaan alat lab antar sumber data. Model tree bisa melakukan split otomatis di sekitar nilai null tanpa memerlukan imputasi eksplisit yang berisiko menghilangkan sinyal, dibantu dengan flag indikator keberadaan data spektral yang eksplisit menandai kelengkapan data tersebut. Model linear maupun neural network membutuhkan imputasi lengkap terlebih dahulu dan lebih rentan bias dari strategi imputasi yang keliru, khususnya pada data spektral bervolume tinggi seperti 30 komponen PCA yang dipakai di sini.

9. Menurut Anda, apakah metrik penilaian RMSE tepat untuk kasus prediksi kandungan organik tanah ini? Jika tidak, metrik apa yang lebih tepat? Elaborasikan jawaban Anda dengan mempertimbangkan karakteristik distribusi target!

Berdasarkan nilai skewness dan kurtosis di atas, distribusi target kandungan organik tanah bersifat right-skewed berat dengan outlier ekstrim. RMSE menjadi kurang ideal untuk distribusi seperti ini karena metrik tersebut sensitif terhadap outlier akibat proses pengkuadratan error besar. Hal ini sebenarnya sudah diantisipasi dalam pipeline, di mana target di-winsorize pada persentil 99 untuk kebutuhan training, dan loss function yang dipakai saat training adalah Huber yang lebih robust terhadap outlier, meskipun RMSE tetap dipakai sebagai metrik evaluasi akhir karena itu merupakan standar penilaian kompetisi.

Metrik alternatif yang lebih sesuai dengan karakteristik distribusi ini adalah MAE yang tidak mengkuadratkan outlier, RMSE pada skala transformasi log atau Box-Cox terhadap target, atau menggunakan Huber loss juga sebagai metrik evaluasi, bukan hanya sebagai loss function saat training.

10. Jika Anda boleh mengambil data eksternal, data tentang apa yang akan Anda ambil untuk meningkatkan akurasi prediksi kandungan organik tanah? Jelaskan alasan pemilihannya dan bagaimana data tersebut dapat diintegrasikan ke dalam pipeline pemodelan Anda!

```
Skewness: 2.0278
Kurtosis: 6.0820
count      11210.000000
mean        34.142518
std         23.198610
min         2.157373
25%         18.121936
50%         27.506510
75%         43.686810
95%         78.684799
max         195.231500
Name: property_organic_content, dtype: float64
```

Ada beberapa jenis data eksternal yang bisa meningkatkan akurasi prediksi. Data curah hujan dan suhu historis relevan karena iklim mempengaruhi laju dekomposisi bahan organik, konsisten dengan temuan pada nomor 3 di mana wilayah yang lebih dingin dan subtropis menunjukkan akumulasi organik yang lebih tinggi [6], [7]. Data satelit berupa indeks vegetasi atau tutupan vegetasi bisa menjadi proxy biomassa yang menjadi input bahan organik ke tanah [8], [9]. Data peta tanah nasional atau model elevasi digital juga relevan karena topografi mempengaruhi drainase dan pola akumulasi bahan organik [1], [10]. Integrasi ke pipeline dilakukan dengan cara join berdasarkan koordinat lintang dan bujur sebagai fitur tambahan sebelum tahap PCA atau pemodelan tree, konsisten dengan struktur fitur spasial yang sudah ada seperti target encoding berbasis zona geografis.

Referensi

- [1] X. Xu, C. Du, Z. Qiu, dan J. Zhou, "A Framework for High-Resolution Mapping of Soil Organic Matter (SOM) by the Integration of Fourier Mid-Infrared Attenuation Total Reflectance Spectroscopy (FTIR-ATR), Sentinel-2 Images, and DEM Derivatives," *Remote Sens*, vol. 15, hlm. 1072, Feb 2023, doi: 10.3390/rs15041072.
- [2] A. Gholizadeh, L. Borůvka, M. Saberioon, dan R. Vašát, "Visible, Near-Infrared, and Mid-Infrared Spectroscopy Applications for Soil Assessment with Emphasis on Soil Organic Matter Content and Quality: State-of-the-Art and Key Issues," *Appl. Spectrosc.*, vol. 67, hlm. 1349–1362, Des 2013, doi: 10.1366/13-07288.
- [3] J. Wetterlind, B. Stenberg, dan M. Söderström, "The use of near infrared (NIR) spectroscopy to improve soil mapping at the farm scale," *Precis. Agric.*, vol. 9, hlm. 57–69, Jan 2008, doi: 10.1007/s11119-007-9051-z.
- [4] T. T. Nguyen *dkk.*, "A novel intelligence approach based active and ensemble learning for agricultural soil organic carbon prediction using multispectral and SAR data fusion," *Sci. Total Environ.*, vol. 804, hlm. 150187, Sep 2021, doi: 10.1016/j.scitotenv.2021.150187.
- [5] C. Cerri, B. Volkoff, dan F. Andreaux, "Nature and behaviour of organic matter in soils under natural forest, and after deforestation, burning and cultivation, near Manaus," *For. Ecol. Manag.*, vol. 38, hlm. 247–257, Feb 1991, doi: 10.1016/0378-1127(91)90146-m.
- [6] T. Tan *dkk.*, "Importance of Terrain and Climate for Predicting Soil Organic Carbon Is Highly Variable across Local to Continental Scales," *Environ. Sci. Technol.*, Jun 2024, doi: 10.1021/acs.est.4c01172.
- [7] M. Gmach, M. Cherubin, K. Kaiser, dan C. Cerri, "Processes that influence dissolved organic matter in the soil: a review," *Sci. Agric.*, vol. 77, Sep 2019, doi: 10.1590/1678-992x-2018-0164.
- [8] S. Mundada dan P. Jain, "Predicting soil organic carbon with ensemble learning techniques by using satellite images for precision farming," *Sci. Rep.*, vol. 15, Agu 2025, doi: 10.1038/s41598-025-09804-3.
- [9] W. Salazar-Coronel, C. Carbajal-Llosa, dan R. Chuchon-Rejon, "Soil organic carbon content mapping along the coast of northern Peru: an ensemble machine learning approach," *Front. Soil Sci.*, Mar 2026, doi: 10.3389/fsoil.2026.1745154.
- [10] M. Wiesmeier *dkk.*, "Soil organic carbon storage as a key function of soils - A review of drivers and indicators at various scales," *Geoderma*, Jul 2018, doi: 10.1016/j.geoderma.2018.07.026.