

SOAL SELEKSI PESERTA

DATA SCIENCE ACADEMY COMP FEST 18

Bagian 1: Kaggle *Competition* (Bobot: 10%)

untuk detail lebih lanjut dapat dilihat pada link kompetisi Kaggle berikut:

<https://www.kaggle.com/t/ec937e759606422a8fd7f5b9e6794680>

Bagian 2: Research Questions (Bobot: 90%)

Setelah memprediksi data **kandungan organik tanah** pada kompetisi Kaggle di atas, akan ada bagian research question di mana kalian akan menjawab pertanyaan-pertanyaan yang berkaitan dengan dataset tersebut. Untuk konsistensi, Anda boleh menggunakan **Training Dataset** untuk tahap ini. Jawaban harap dikumpulkan dalam bentuk **PDF** atau **python notebook** dengan format **.ipynb**. Anda bebas menggunakan alat-alat visualisasi, uji hipotesis, sitasi sumber, ataupun hal lainnya untuk mendukung jawaban Anda.

1. Dalam konteks bisnis pertanian dan kebijakan pangan, apakah memprediksi kandungan organik tanah merupakan hal yang mendesak? Jelaskan urgensinya dari perspektif efisiensi biaya operasional dan manajemen lahan berkelanjutan!
2. Apakah model prediksi kandungan organik tanah Anda mengalami *overfit* atau *underfit*? Tunjukkan buktinya secara empiris melalui metrik evaluasi atau melalui visualisasi yang relevan, serta jelaskan langkah mitigasi yang Anda lakukan! Jika tidak mengalami keduanya, jelaskan alasannya!
3. Apakah ada pola distribusi kandungan organik tanah yang berbeda secara signifikan antar wilayah geografis? Berdasarkan pola tersebut, kira-kira kondisi ekosistem seperti apa yang paling dominan dalam dataset ini? Jelaskan reasoning Anda berdasarkan informasi ekologis dan tutupan lahan yang terlihat!

4. Apakah ada korelasi kandungan organik tanah antar tingkat wilayah geografis? Berapa rasio perbandingan rata-rata kandungan organik antar wilayah tersebut, dan bagaimana ini memengaruhi pendekatan pemodelan Anda?

5. Jawablah pertanyaan statistik berikut :

- a. Berapa rata-rata kandungan organik tanah dari tiap ekosistem ketika tingkat keasaman tanah berada di bawah persentil 25 dan kapasitas tukar kation berada di bawah rata-rata? Apa insight yang bisa didapat dari hal ini?
- b. Apakah ada kombinasi jenis tutupan lahan dan wilayah geografis tertentu yang memiliki nilai kandungan organik yang dapat dianggap sebagai *outlier*? Jelaskan justifikasi Anda!

6. Apakah ada pasangan variabel yang berkorelasi tinggi? Apakah ada efek multicollinearity yang perlu diatasi dalam modeling?

7. Fitur baru apa saja yang Anda buat melalui proses *feature engineering*? Jelaskan bagaimana fitur tersebut meningkatkan pemahaman model terhadap pola kandungan organik tanah!

8. Jelaskan model yang Anda gunakan dalam memprediksi kandungan organik tanah! Mengapa Anda memilih model tersebut dibanding alternatif lain, khususnya dalam konteks data yang memiliki representasi spektral?

9. Menurut Anda, apakah metrik penilaian RMSE tepat untuk kasus prediksi kandungan organik tanah ini? Jika tidak, metrik apa yang lebih tepat? Elaborasikan jawaban Anda dengan mempertimbangkan karakteristik distribusi target!

10. Jika Anda boleh mengambil data eksternal, data tentang apa yang akan Anda ambil untuk meningkatkan akurasi prediksi kandungan organik tanah? Jelaskan alasan pemilihannya dan bagaimana data tersebut dapat diintegrasikan ke dalam pipeline pemodelan Anda!

Detail Bobot Penilaian:

Soal	Bobot Penilaian
Submisi Kompetisi Kaggle	10%
Nomor 1	2.5%
Nomor 2	10%
Nomor 3	12.5%
Nomor 4	7.5%
Nomor 5	5% +5%
Nomor 6	7.5%
Nomor 7	10%
Nomor 8	10%
Nomor 9	10%
Nomor 10	10%
Total	100%